

Lab1 : Regression lineaire simple

Modélisation, évaluation, vérification des hypothèses graphiques et tests statistiques.

Dr ASSOHOUN Egomli Stanislas

1. Mise en œuvre du modèle

Nous allons prédire la consommation de carburant (mpg, miles per gallon) en fonction du poids du véhicule (wt, weight).

Code R pour construire le modèle :

```
# Charger les données
data(mtcars)

# Construire le modèle de régression linéaire simple
model <- lm(mpg ~ wt, data = mtcars)

# Résumé du modèle
summary(model)
```

Résultats du modèle :

Le résumé du modèle donne les informations suivantes :

- **Formule du modèle** : $\text{mpg} = \beta_0 + \beta_1 \cdot \text{wt}$
- **Coefficients estimés** : - Intercept (β_0) : 37.2851
- Pente (β_1) : -5.3445
- **Significativité des coefficients** :
 - Les deux coefficients sont significatifs ($p < 0.001$).
- **R^2** : 0.7528 (75.28 % de la variance de mpg est expliquée par wt).
- **Erreur standard résiduelle** : 3.046.

2. Évaluation du modèle

a) Coefficient de détermination (R^2)

Le R^2 est donné dans le résumé du modèle :

$$R^2 = 0.7528$$

Cela signifie que 75.28 % de la variance de la consommation (mpg) est expliquée par le poids (wt).

b) Erreur quadratique moyenne (MSE)

Calculons la MSE pour évaluer la précision du modèle :

```
# Calcul de la MSE
mse <- mean(residuals(model)^2)
cat("MSE:", mse, "\n")
```

Résultat : MSE = 9.279.

c) Prédiction

Vous pouvez prédire la consommation pour de nouvelles valeurs de poids :

```
# Prédire pour un poids de 3.5
predict(model, newdata = data.frame(wt = 3.5))
```

3. Vérification des hypothèses graphiques

Les hypothèses de la régression linéaire simple sont :

1. **Linéarité** : La relation entre mpg et wt est linéaire.
2. **Indépendance des erreurs** : Les résidus ne sont pas corrélés.
3. **Homoscedasticité** : La variance des résidus est constante.
4. **Normalité des résidus** : Les résidus suivent une distribution normale.

a) Graphiques de diagnostic

Utilisez la fonction plot() pour vérifier ces hypothèses :

```
# Graphiques de diagnostic
par(mfrow = c(2, 2)) # Afficher 4 graphiques sur une seule fenêtre
plot(model)
```

Interprétation des graphiques :

1. **Résidus vs valeurs ajustées** : Vérifie l'hypothèse d'homoscedasticité (les résidus doivent être répartis de manière aléatoire autour de 0).
2. **QQ-plot** : Vérifie la normalité des résidus (les points doivent suivre la ligne diagonale).
3. **Échelle des résidus** : Vérifie la variance constante des résidus.
4. **Leverage plot** : Identifie les points influents.

4. Tests statistiques

a) Test de significativité globale (F-statistique)

Le test F dans le résumé du modèle évalue si le modèle est globalement significatif :

- H_0 : Le modèle n'explique pas mieux les données qu'un modèle sans variable explicative.
- H_1 : Le modèle explique significativement les données.

Résultat dans le résumé :

$$F = 91.38, \quad p < 0.001$$

Le modèle est significatif.

b) Test de significativité des coefficients (*t*-tests)

Pour chaque coefficient (β_0 et β_1), le *t*-test vérifie : - H_0 : Le coefficient est nul ($\beta = 0$). - H_1 : Le coefficient est significatif ($\beta \neq 0$).

Résultats :

- Intercept (β_0) : $t = 19.858, p < 0.001$

- Pente (β_1) : $t = -9.559, p < 0.001$

Les deux coefficients sont significatifs.

c) Test de normalité des résidus

Utilisez le test de Shapiro-Wilk pour vérifier la normalité des résidus :

```
shapiro.test(residuals(model))
```

- H_0 : Les résidus suivent une distribution normale.
- H_1 : Les résidus ne suivent pas une distribution normale.

5. Résumé des résultats

1. Modèle :

- $\text{mpg} = 37.2851 - 5.3445 \cdot \text{wt}$
- Le poids a un effet négatif significatif sur la consommation.

2. Évaluation :

- $R^2 = 0.7528$: Le modèle explique 75.28 % de la variance.
- $\text{MSE} = 9.279$.

3. Hypothèses :

- Les graphiques de diagnostic montrent que les hypothèses sont globalement respectées.
- Les résidus sont normalement distribués (vérifié par le test de Shapiro-Wilk).

4. Tests statistiques :

- Le modèle est significatif ($F = 91.38, p < 0.001$).
- Les coefficients sont significatifs ($p < 0.001$).